

Compte-rendu hebdomadaire

Compte-rendu 4

Valentin Noyé

10 février 2025 - 14 février 2025

GitHub : <https://github.com/owilo/Stage>

1 Problématique


Analyser les différences entre diverses architectures d'auto-encodeurs permet d'établir les fondements nécessaires pour comprendre non seulement leur principe et les mécanismes qu'elles implémentent, mais aussi percevoir ce phénomène d'emmêlage des caractéristiques latentes sous un autre éclairage, d'autant plus rigoureux en explorant les principes mathématiques qui les définissent.

2 Travail réalisé

2.1 Compréhension des auto-encodeurs variationnels

2.1.1 Auto-encodeur simple

Un auto-encodeur simple fonctionne sur la base d'un encodeur et d'un décodeur seulement entraînés à reconstruire les images par une fonction de perte entre l'image source et reconstruite sans se soucier de la structure de l'espace latent. Les images dans la figure 1 tirées de [ce site](#) montrent la différence entre un auto-encodeur simple et variationnel en leur qualité de reconstruction d'images interpolées qui n'ont pas été décrites lors de l'entraînement de l'auto-encodeur. Par extension à cela, la génération d'images décodées à partir de bruit ne permet pas de générer des chiffres (ou glyphes) de bonne qualité avec un auto-encodeur simple plutôt qu'un VAE.



(a) Auto-encodeur simple

(b) Auto-encodeur variationnel

FIGURE 1 – Reconstruction de vecteur latents interpolés

2.1.2 Théorie

Les auto-encodeurs variationnels s'appuient sur une approche bayésienne pour modéliser la reconstruction et la structuration de l'espace latent, ce qui permet la génération des données. On note :

- **Données observées** : x une image issue de notre ensemble d'entraînement ;
- **Variable latente** : z un vecteur qui capture les caractéristiques essentielles de x ;
- **Vraisemblance marginale (évidence)** : $p(x)$, la distribution de notre ensemble d'entraînement définie par :

$$p(x) = \int p(z)p(x|z)dz$$

- **Prior sur le latent** : $p(z)$, la distribution sur la variable latente z . Dans les VAE, on suppose que $p(z) = \mathcal{N}(z; 0, I)$ soit une gaussienne centrée réduite ;
- **Postérieure** : $p(z|x)$ est la distribution réelle des latents compte tenu de x , mais elle est insoluble ;
- **Postérieure approximée (encodeur)** : On approxime $p(z|x)$ par

$$q(z|x) = \mathcal{N}(z; \mu(x), \text{diag}(\sigma^2(x)))$$

où $\mu(x)$ et $\sigma(x)$ sont deux sorties de l'encodeur. Or, lors de l'apprentissage d'un VAE, l'échantillonnage direct du vecteur latent z à partir de la distribution $q(z|x)$ pose un problème pour la rétropropagation des gradients, car l'opération d'échantillonnage est non-différentiable. Pour contourner ce problème, on utilise le «reparameterization trick» défini par

$$z = \mu(x) + \sigma(x) \cdot \varepsilon$$

où $\varepsilon \sim \mathcal{N}(0, 1)$, et permet de modéliser un échantillonnage aléatoire sur notre gaussienne ;

- **Vraisemblance (décodeur)** : $p(x|z)$ est la vraisemblance et définit la probabilité de générer un x à partir d'un z donné. Cette distribution est connue ;
- **Postérieure agrégée** : $q(z)$, comme parfois vu en littérature, représente la distribution globale des variables latentes z induites par l'ensemble de données et le modèle d'inférence $q(z|x)$, ce qui peut être utile pour analyser la correspondance entre cette distribution agrégée et le prior $p(z)$. Elle est définie comme tel :

$$q(z) = \int p(x)q(z|x)dx$$

L'objectif est de maximiser la log-vraisemblance des données $\ln p(x)$ qui s'exprime par :

$$\ln p(x) = \ln \int p(z)p(x|z)dz$$

Cependant cette intégrale ne peut pas être résolue. Pour y remédier on introduit la distribution $q(z|x)$:

$$\ln p(x) = \ln \int q(z|x) \frac{p(z)p(x|z)}{q(z|x)} dz = \ln \mathbb{E}_{q(z|x)} \left[\frac{p(z)p(x|z)}{q(z|x)} \right].$$

En appliquant l'inégalité de Jensen, on obtient :

$$\ln p(x) \geq \mathbb{E}_{q(z|x)} \left[\ln \frac{p(z)p(x|z)}{q(z|x)} \right].$$

Cette borne inférieure est appelée l'«Evidence Lower BOund» (ELBO) et s'écrit, par simplification des termes :

$$\mathcal{L}(x) = \mathbb{E}_{q(z|x)} [\ln p(x|z)] - D_{\text{KL}}(q(z|x) \parallel p(z)).$$

- $\mathbb{E}_{q(z|x)} [\ln p(x|z)]$ est le terme de reconstruction. Il incite le décodeur à générer des données x cohérentes à partir des latents z échantillonnés ;
- $D_{\text{KL}}(q(z|x) \parallel p(z))$ est la divergence de Kullback-Leibler entre la distribution approximative $q(z|x)$ et le prior $p(z)$. Ce terme régularise l'encodeur en le contraignant à ne pas s'éloigner trop du prior choisi.

Notre fonction de perte vise donc à maximiser la qualité reconstruction, soit minimiser l'erreur de reconstruction, ainsi qu'à minimiser la divergence entre ces deux distributions.

2.1.3 β -VAE

L'article [3] discute de la pondération de la divergence de Kullback-Leibler dans la fonction de perte discutée dans 2.1.2 par un facteur β .

$$\mathcal{L}_\beta(x) = \mathbb{E}_{q(z|x)} [\ln p(x|z)] - \beta D_{\text{KL}}(q(z|x) \parallel p(z)).$$

En augmentant le facteur β , on renforce la contrainte sur l'espace latent ce qui encourage souvent l'apprentissage de représentations plus démêlées (c'est-à-dire, des caractéristiques latentes plus séparées et interprétables), mais cela peut se faire au détriment de la qualité de reconstruction, car le modèle privilégie la régularisation. Si on réduit en revanche le facteur β , la contrainte sur l'espace latent est plus faible, ce qui peut améliorer la qualité de la reconstruction, mais au risque d'obtenir un espace latent moins organisé et plus sujet à l'overfitting.

2.1.4 Autres auto-encodeurs variationnels

D'autres chercheurs emploient diverses méthodes de démêlage basées sur les VAEs ou β -VAEs, tels que présentées dans les β -TCVAEs [1], les FactorVAEs [4] ainsi que les HFVAEs [2].

2.1.5 Analyse de la variance autour du centroïde dans le vecteur latent

On emploie un diagramme sous forme de boîtes à moustaches dans les figures 2 et 3 sur les distributions $q(z|x)$ générées par notre auto-encodeur afin d'analyser la distribution des dimensions individuelles pour chaque classe.

Nous observons qu'avec un facteur β très élevé, seulement quelques dimensions sont suffisantes pour décrire les quelques caractéristiques de nos chiffres, tandis qu'avec un $\beta = 1$ (VAE classique), l'ensemble des dimensions du vecteur latent ne contrôlent pas nécessairement une unique caractéristique de nos chiffres puisque nous avons un emmêlage plus important.




FIGURE 2 – Distribution de l'espace latent de la classe 0




FIGURE 3 – Distribution de l'espace latent de la classe 1

2.1.6 Analyse du pouvoir discriminant des dimensions par ANOVA

Le score ANOVA de nos vecteurs latents se définit essentiellement par le ratio entre leur variance entre chaque class sur leur variance pour chaque classe. Cela signifie que les dimensions au score le plus élevé ont un pouvoir plus discriminant entre les classes. La figure 4 montre qu'avec un β suffisamment grand, 4 caractéristiques permettent d'encoder l'information sur la classe, tandis que c'est moins clair avec un $\beta = 1$.




FIGURE 4 – Pouvoir discriminant des dimensions par ANOVA

Pour $\beta = 100$, nous pouvons voir ce potentiel discriminant sur les figures 5 et 6, où la caractéristique 2 est à la fois une dimension contrôlant le style mais également de contenu d'après la figure 4 (par exemple, un 4 se transforme en 1 s'il est suffisamment fin). La caractéristique 8 est moins discriminante, mais affecte tout de même le style de notre chiffre en l'inclinant. D'autres dimensions telles que celle d'indice 12 n'ont aucun effet sur le chiffre.




FIGURE 5 – Modification de la dimension d'index 2




FIGURE 6 – Modification de la dimension d'index 8

2.2 Ajout de fonctionnalités sur Bokeh

Sur Bokeh, il est à présent possible de visualiser le vecteur latent du chiffre survolé par le curseur (voir figure par la courbe colorée pleine 7). Cliquer dessus permet de le sauvegarder sous forme de pointillés gris afin de pouvoir le comparer lors du survol d'autres chiffres. Les pointillés colorés représentent le centroïde de la classe du chiffre sélectionné.




FIGURE 7 – Nouvel affichage sur Bokeh

3 Travail à effectuer

- Tracer les différentes distributions sur un vecteur latent de taille 16 ;
- Explorer les auto-encodeurs semi-supervisés (CVAEs) ou les AAEs tels que décrits dans [6] et [5] dans la dissociation complète du contenu (classe) et du style ;

- Effectuer une classification sur trois classes afin de reconnaître la présence de traces d’une classe par rapport à sa translation.

4 Activités

Réunions :

- «*3D self-assembly using DNA as programmable methods* » par Gaetan Bellot - Inserm - Mardi 11/02/25

Références

- [1] Ricky T. Q. Chen, Xuechen Li, Roger Grosse, and David Duvenaud. Isolating sources of disentanglement in variational autoencoders, 2019.
- [2] Babak Esmaeili, Hao Wu, Sarthak Jain, Aican Bozkurt, N. Siddharth, Brooks Paige, Dana H. Brooks, Jennifer Dy, and Jan-Willem van de Meent. Structured disentangled representations, 2018.
- [3] Irina Higgins, Loic Matthey, Arka Pal, Christopher Burgess, Xavier Glorot, Matthew Botvinick, Shakir Mohamed, and Alexander Lerchner. beta-VAE : Learning basic visual concepts with a constrained variational framework. In *International Conference on Learning Representations*, 2017.
- [4] Hyunjik Kim and Andriy Mnih. Disentangling by factorising, 2019.
- [5] Alireza Makhzani, Jonathon Shlens, Navdeep Jaitly, Ian Goodfellow, and Brendan Frey. Adversarial autoencoders, 2016.
- [6] N. Siddharth, Brooks Paige, Jan-Willem van de Meent, Alban Desmaison, Noah D. Goodman, Pushmeet Kohli, Frank Wood, and Philip H. S. Torr. Learning disentangled representations with semi-supervised deep generative models, 2017.