

Compte-rendu hebdomadaire

Compte-rendu 7

Valentin Noyé

3 mars 2025 - 7 mars 2025

GitHub : <https://github.com/owilo/Stage>

1 Problématique

Le compte-rendu de cette semaine se concentre principalement sur la présentation des résultats et inclut deux analyses supplémentaires pour les étayer.

2 Travail réalisé

2.1 Diaporama de présentation

Afin de présenter les résultats de manière synthétique durant la présentation du 24 mars, une ébauche de diaporama a été conceptionnée et est disponible sur le répertoire GitHub dans le dossier `/Slides`. Les références renseignées dans ce diaporama sont [1], [3] et [2].

2.2 Distribution de la certitude des prédictions

Dans cette partie nous visons à comprendre deux choses, qui sont présentées par la figure 1. Tout d'abord, la part d'images correctement classifiées est proche de 86% comme indiqué dans les précédents comptes-rendus. La translation vers toutes les classes source jusqu'à toute classe cible sauf elle-même confère une précision de classification de 85,79% sur la classe cible, ce qui est proche des 86,77% que nous connaissons et qui considèrerait également la reconstruction (translation d'un chiffre vers sa propre classe). Mise à part cela, seulement 1,59% des classes translatées sont classifiées comme appartenant à la classe source. Autrement, 12,62% sont classifiées dans d'autres classes.

Pour mettre en relation ces données de classification avec la certitude obtenue lors de celle-ci, nous employons le graphe en barres permettant de visualiser le pourcentage de bonnes et mauvaises classifications en fonction des probabilités générées par le classifieur. Nous voyons que la majorité des mauvaises classifications prend place lorsque la probabilité de sortie du classifieur n'est pas élevée (moins de 60%). À l'inverse, le classifieur détermine correctement la classe lorsque la certitude est très grande (plus de 99%).




FIGURE 1 – t-SNE des 6 vecteurs latents

2.3 Prototype global

Il peut être intéressant de voir à quoi ressemble le prototype global, calculé à partir de l'ensemble des images d'entraînement de MNIST, à l'instar des centroïdes des classes. Visuellement, il ressemble à un 8.



FIGURE 2 – Prototype global du dataset MNIST

D'autres analyses récréatives permettent de constater que le classifieur détermine la classe de ce prototype global comme étant celle des huit. Les translations et les classifications associées à ce superprototype sont plutôt qualitatives (voir figure 3).




FIGURE 3 – Translation du prototype global

Ce dernier se projette alors dans la classe des 8 avec un t-SNE (voir figure 4). Il se situe

très proche du centre de la projection, et les translations vers d'autres classes finissent souvent proches de leur centroïde.




FIGURE 4 – t-SNE de la translation du prototype global

3 Travail à effectuer

- Compléter les slides de présentation ;
- Analyser les traces et déterminer une méthode permettant de diminuer leur visibilité ou de les masquer ;
- Explorer les méthodes d'empoisonnement [2] afin de tromper le classifieur dans la détection de la classe source ;
- Implémenter une méthode de chiffrement par clé, renvoyant un vecteur de translation avec un angle et une longueur déterminée par la clé ;
- Potentiellement explorer davantage l'utilisation des CVAE [3] pour arriver à nos fins.

4 Activités

Réunions :

- «*Clustered Rendering* » par Arthur Chateauneuf - "Speech Lunch" - Mardi 04/03/25
- Réunion de suivi - Mercredi 05/03/25

Références

- [1] Irina Higgins, Loic Matthey, Arka Pal, Christopher Burgess, Xavier Glorot, Matthew Botvinick, Shakir Mohamed, and Alexander Lerchner. beta-VAE : Learning basic visual concepts with a constrained variational framework. In *International Conference on Learning Representations*, 2017.
- [2] Pol Labarbarie. *Transferable adversarial patches : a potential threat for real-world computer vision algorithms*. PhD thesis, Milad Informatique université Paris-Saclay, 2024.
- [3] N. Siddharth, Brooks Paige, Jan-Willem van de Meent, Alban Desmaison, Noah D. Goodman, Pushmeet Kohli, Frank Wood, and Philip H. S. Torr. Learning disentangled representations with semi-supervised deep generative models, 2017.