

Compte-rendu hebdomadaire

Compte-rendu 8

Valentin Noyé

10 mars 2025 - 14 mars 2025

GitHub : <https://github.com/owilo/Stage>

1 Problématique

Alors que la reconnaissance de la classe source atteint une précision de 71,75%, nous n'avons encore qu'une compréhension limitée de l'interprétation des traces de la translation, ce qui ne nous permet pas de tirer de conclusions claires sur les stratégies d'attaque et de défense de notre modèle. Afin de mieux comprendre ce processus et de développer une méthode de défense efficace, nous procédons à une analyse supplémentaire des vecteurs latents générés lors de la translation, sur la base de l'hypothèse concernant la nature de ces traces.

2 Travail réalisé

2.1 Diaporama de présentation

Le diaporama a été complété, et est prêt à être présenté le 24 mars. Il peut être trouvé sous le répertoire GitHub dans le dossier `/Slides`. Les références renseignées dans ce diaporama sont [1], [3] et [2]

2.2 Approximation de la distribution des dimensions latentes

Une hypothèse sur la présence de traces a été émise en lien avec la variation de la distribution des dimensions des vecteurs latents. En effet, notre méthode de translation "classique" déplaçait le centre de la distribution de la classe source vers celui de la classe de destination, sans prendre en compte l'écart-type de cette dernière. Nous pouvons alors en déduire que les traces de la classe source correspondaient à des dimensions sous-évaluées ou surévaluées par rapport à la distribution de destination. La figure 1 illustre cela en comparant le vecteur rouge (distribution de la translation d'un 0 vers 1) et le vecteur vert (distribution de la classe destination 1).

En normalisant selon la formule

$$V_T = V_{dst} + \left(\frac{\sigma_{dst}}{\sigma_{src}} \right) (V_I - V_{src})$$

nous approximations alors la distribution de destination (vecteur violet).




FIGURE 1 – Approximation de la distribution par normalisation de la translation de 0 vers 1

Cette nouvelle approche à la translation ne fait pas varier grandement les résultats, mais nous pouvons constater des légères améliorations dans la translation, vers la classe des 1 notamment (voir figure 2).




FIGURE 2 – Grilles de translation

La classification de la translation présente une précision légèrement supérieure à ce que nous avons précédemment (voir tableau 1), tandis que la classification de la translation inverse et la détection de la translation ne font pas voir beaucoup de différence. Une chose intéressante à remarquer concerne la reconnaissance de la classe source qui s'aligne un peu mieux avec notre choix de défendre contre de telles attaques, c'est à dire en limitant au maximum le classifieur à

reconnaître la classe d’origine. Hélas nous avons tout de même une classification majoritairement correcte, donc une telle mesure de défense ne peut pas être suffisante.

Classification	Ancienne méthode	Nouvelle méthode
Translation	86.77%	89.13%
Translation inverse	96.41%	96.15%
Détection de la translation	99.84%	99.79%
Reconnaissance de la classe source	71.75%	67.79%

TABLE 1 – Comparaison des méthodes

La figure 3 détaille les résultats renseignés dans la tableau précédent sous forme de matrices de confusion.




FIGURE 3 – Diverses classifications obtenues à partir de la nouvelle méthode

2.3 Analyse de l’interdépendance d’une dimension latente avec les autres

En faisant varier la dimension latente z_0 (première dimension) à différentes valeurs présentes dans l’écart interquartile de la distribution de z_0 , nous sommes en mesure d’évaluer l’écart de la moyenne sur les dimensions z_i , $i > 0$. La figure 4 met donc en évidence les dimensions latentes de la classe 1 dont la moyenne varie ou non en fonction de z_0 . Quand elles ne varient pas grandement,

elles sont indépendantes (par exemple, $z_1, z_{15}, \dots$), tandis que d'autres sont un peu plus emmêlées avec z_0 (telles que $z_3, z_7, \dots$).




FIGURE 4 – Déplacement de la moyenne des dimensions latentes en fonction de z_0

La figure 5 montre ce même fonctionnement sous plusieurs courbes d'évolution de la moyenne des z_i , avec $i > 0$, en fonction de la valeur prise par z_0 . Quand la courbe de z_i est constante, cette dimension ne dépend pas de z_0 . À l'inverse, elle croît ou décroît si elle en dépend.




FIGURE 5 – Évolution de la moyenne des dimensions latentes en fonction de z_0

Cela nous amène à supposer que la translation doit suivre une distribution déterminée par l'interdépendance entre les dimensions latentes, plutôt que par la distribution d'une dimension prise isolément (telle que lors de la translation classique ou avec normalisation).

3 Travail à effectuer

- Mener l'étude de la reconnaissance de la classe source à partir du CVAE puis l'utiliser pour transformer des images réelles tout en maintenant le style, possiblement de la manière décrite dans [3] ;
- Continuer l'analyse des traces ainsi que l'implémentation d'une méthode de défense contre la reconnaissance de la classe source ;
- Explorer les méthodes d'empoisonnement [2] afin de tromper le classifieur dans la détection de la classe source ;
- Implémenter une méthode de chiffrement par clé, renvoyant un vecteur de translation avec un angle et une longueur déterminée par la clé.

4 Activités

Réunions :

- «*Embryo-développement du massif facial humain entre 6 et 14 semaines en micro-imagerie multimodale (micro TDM et IRM haut champ)* » par Romain Martineau - Mardi 11/03/25
- «*Bruits à variation spatiale en temps réel* » par Arthur Chateauneuf - Mardi 11/03/25
- Réunion de suivi - Mercredi 12/03/25

Références

- [1] Irina Higgins, Loic Matthey, Arka Pal, Christopher Burgess, Xavier Glorot, Matthew Botvinick, Shakir Mohamed, and Alexander Lerchner. beta-VAE : Learning basic visual concepts with a constrained variational framework. In *International Conference on Learning Representations*, 2017.
- [2] Pol Labarbarie. *Transferable adversarial patches : a potential threat for real-world computer vision algorithms*. PhD thesis, Milad Informatique université Paris-Saclay, 2024.
- [3] N. Siddharth, Brooks Paige, Jan-Willem van de Meent, Alban Desmaison, Noah D. Goodman, Pushmeet Kohli, Frank Wood, and Philip H. S. Torr. Learning disentangled representations with semi-supervised deep generative models, 2017.