

Compte-rendu hebdomadaire

Compte-rendu 9

Valentin Noyé

17 mars 2025 - 21 mars 2025

GitHub : <https://github.com/owilo/Stage>

1 Problématique

Il est à présent envisageable d'employer le CVAE pour effectuer une variété de tests que nous menions précédemment avec le β -VAE sur plusieurs aspects de la transformation de chiffres, découplant le style et la classe, et en ne modifiant que cette dernière.


2 Travail réalisé

2.1 Résultats de tests menés avec le CVAE


2.1.1 Grilles de transformation

Une refonte du code a permis d'obtenir des résultats avec le CVAE de la même manière qu'avec le β -VAE. Nous nous référons à présent à une «transformation» par CVAE pour décrire le processus de translation précédemment appliqué avec notre β -VAE.

La figure 1 met en évidence les résultats obtenus à partir de notre CVAE sur deux tailles de vecteurs latents différentes. Tandis que d'une part nous constatons l'efficacité visuelle de la transformation, il n'est pas simple d'en déduire, entre les deux tailles de 16 et 128 sélectionnées, si l'une permet de conserver le style mieux que l'autre. En effet, les essais qui ont été menés à cet égard présentaient des résultats variables en leur qualité de conservation du style qu'un vecteur latent d'une certaine taille possédait à l'inverse de l'autre. L'épaisseur, par exemple, était mieux conservée dans un vecteur latent de taille 16 tandis que la largeur l'était mieux dans un vecteur latent de taille 128.



(a) Vecteur latent de 16



(b) Vecteur latent de 128

FIGURE 1 – Grilles de transformation du CVAE

L'avantage de cet autoencodeur variationnel conditionnel réside en ses performances de transformation qui excelle celles du β -VAE, ce qui s'observe notamment lors de la translation depuis la classe sources des 2 dans la figure 2. Quant à la translation inverse, il semblerait tout de même que le CVAE laisse paraître plus de variation que notre β -VAE, mais reconstruit assez correctement l'image originale.




FIGURE 2 – Comparaison des transformations de la classe 2 entre le β -VAE et le CVAE

2.1.2 Classification de la transformation avec le CVAE

Le tableau 1 recense la précision de classification pour chacune des méthodes de transformation explorées dans les derniers comptes-rendus, à savoir la translation par β -VAE, la translation normalisée par β -VAE ainsi que la transformation par CVAE. Il est clair que nous obtenons une très bonne classification avec notre CVAE, ainsi qu'une défense accrue aux attaques de reconnaissance de la classification que nous n'obtenions pas avec notre β -VAE.

Classification	β -VAE	β -VAE + normalisation	CVAE
Translation/Transformation	86,77%	89,13%	99,18%
Trans. inverse	96,41%	96,15%	99,73%
Détection de la trans.	99,84%	99,79%	90,00% (N/A ?)
Reco. de la classe source	71,75%	67,79%	21,63%

TABLE 1 – Comparaison de la précision du β -VAE et du CVAE

Les matrices dans la figure 3 mettent en relation la précision obtenue avec les résultats de classification. La précision de 90,00% de notre détecteur de la transformation paraît surprenant, puisque le classifieur reconnaît une transformation 100% du temps alors qu'elle ne pas prend

nécessairement place. Une raison hypothétique pour laquelle nous observons cela concerne la distribution déséquilibrée des labels dans le dataset d'entraînement, où 90% des images d'entraînement sont labélisées comme transformées tandis que seulement 10% sont labélisées comme non-transformées. Par ailleurs, si le classifieur n'est pas capable de détecter correctement cette transformation, il va tout de même tenter d'atteindre une précision optimale. Ainsi, la précision de 90% serait donc est une conséquence du premier point évoqué.




FIGURE 3 – Diverses classifications obtenues avec le CVAE

2.1.3 Transformation d'une image réelle

La transformation d'une image réelle à partir de notre CVAE confère des résultats cohérents mais présente toujours des artéfacts lors de la transformation (voir figure 4). Nous pouvons attribuer ce problème à la faible variation du dataset qui ne capture pas celle d'une image externe, telle qu'une image réelle.




FIGURE 4 – Transformation d’une image réelle d’un 2

3 Travail à effectuer

- Continuer l’analyse des traces ainsi que l’implémentation d’une méthode de défense contre la reconnaissance de la classe source ;
- Continuer d’étudier et utiliser le CVAE dans le but de transformer des images réelles tout en maintenant le style [3] ;
- Explorer les méthodes d’empoisonnement (voir [2] et [1]) afin de tromper le classifieur dans la détection de la classe source ;
- Implémenter une méthode de chiffrement par clé, renvoyant un vecteur de translation avec un angle et une longueur déterminée par la clé.

4 Activités

Réunions :

- Réunion de suivi - Jeudi 20/03/25

Références

- [1] Ian J. Goodfellow, Jonathon Shlens, and Christian Szegedy. Explaining and harnessing adversarial examples, 2015.
- [2] Pol Labarbarie. *Transferable adversarial patches : a potential threat for real-world computer vision algorithms*. PhD thesis, Milad Informatique université Paris-Saclay, 2024.
- [3] N. Siddharth, Brooks Paige, Jan-Willem van de Meent, Alban Desmaison, Noah D. Goodman, Pushmeet Kohli, Frank Wood, and Philip H. S. Torr. Learning disentangled representations with semi-supervised deep generative models, 2017.