

Compte-rendu hebdomadaire

Compte-rendu 10

Valentin Noyé

24 mars 2025 - 28 mars 2025

GitHub : <https://github.com/owilo/Stage>


1 Problématique

Jusqu'à présent, la transformation d'un chiffre par clé nécessitait la connaissance à la fois de la classe source et de la classe de destination. Cependant, en présence de distorsions ou d'empoisonnement d'un contenu multimédia, ces informations essentielles peuvent être perdues. Il est donc primordial de définir une méthode permettant d'effectuer cette transformation de manière inversible, sans dépendre de ces classes, et en garantissant tout de même qu'un chiffre transformé sorte de sa classe d'origine.

2 Travail réalisé

2.1 Génération aléatoire de chiffres

Nous avons différents moyens de générer aléatoirement des chiffres, or nous souhaitons échantillonner des vecteurs latents de manière à correspondre à la distribution de notre espace latent. Nous comparons dans la figure 1 la différence entre un échantillonnage uniforme sur l'espace latent avec un échantillonnage par un mélange de 25 gaussiennes, ainsi qu'un échantillonnage aléatoire autour de la distribution des caractéristiques d'un chiffre du dataset d'entraînement. Tandis que nous obtenons naturellement des résultats médiocres avec un échantillonnage uniforme, les deux autres méthodes donnent des résultats visuellement très bons. Cet essai nous permet de constater qu'un mélange de gaussiennes approxime très bien cette distribution.



(a) Uniforme

(b) Modèle de mélange gaussien

(c) Alentours d'un chiffre

FIGURE 1 – Échantillonnage aléatoire de chiffres

2.2 Translation indépendante des classes

Une méthode de translation a été mise en place afin de transformer un chiffre en un autre sans connaissance préalable de la classe source et de destination. Pour ce faire, l’algorithme utilisé est le suivant :

1. Calculer la projection 2D de notre dataset d’entraînement. En construire 10 ellipses représentant chacune des classes (75% des points de chaque classe y sont contenus).
2. Déterminer pseudo-aléatoirement ou à partir d’une clé, un vecteur z_t 128-dimensionnel dont la longueur correspond à la moyenne des longueurs inter-centroïdes de chaque classe + une valeur pseudo-aléatoire entre 0 et 1.
3. Pour un chiffre que l’on souhaite transformer, l’encoder en un vecteur latent z^0 . Exclure les ellipses dans lesquelles se situent la projection 2D de ce vecteur, car elles représentent potentiellement la classe source de ce dernier.
4. Appliquer itérativement une translation $z^i = z^{i-1} + z_t$ jusqu’à ce que la projection 2D de z^i tombe dans une ellipse. Ainsi elle appartient à une classe autre que la classe source.
5. Décoder z^i pour obtenir l’image transformée.
6. Pour la transformation inverse, appliquer le processus inverse avec $z_t^{-1} = -z_t$.

La projection 2D se réfère ici à une projection UMAP. Cette projection, à l’inverse du t-SNE, maintient des caractéristiques globales, plutôt que locales, des données hautes-dimensionnelles. Cela signifie que nous n’avons pas à calculer la projection 2D avec l’ensemble du dataset d’entraînement à chaque itération, ce qui s’avèrerait être très coûteux en temps. En effet, cette projection n’est calculée qu’une fois pour l’entièreté du dataset. Ensuite, nous projetons seulement le vecteur latent translaté de manière itérative.

Par ailleurs, effectuer une telle translation sans passage vers une projection 2D est en pratique impossible du fait de l’immense taille d’un espace de 128 dimensions. Le ratio entre l’hypervolume d’un hyperepsilloïde en 128D et de l’AABB englobant chacune des vecteurs latents est extrêmement faible. La translation n’aboutirait presque jamais dans des temps d’exécution raisonnables.

La figure 2 met en évidence que cette méthode ne garantit pas toujours une reconstruction qualitative, ou encore une inversibilité, en revanche, nous sommes en mesure d’obtenir des résultats en très peu d’itérations.




FIGURE 2 – Résultats de la méthode de translation

Nous pouvons observer les étapes de la transformation dans la figure 3. Dans un premier temps nous constatons ce qui peut paraître le plus évident : certaines ellipses n’englobent pas correctement le cluster de la classe correspondante. En effet, le calcul de ces ellipses prend également en compte les petits amas séparés du plus grand cluster de la classe, s’agglutinant à ceux d’autres classes plus éloignées. Cela se constate avec les 1 et les 7, dont certains vecteurs latents projetés avoisinent ceux des 2 et des 3 respectivement. Pour pallier ce problème, nous pouvons considérer un ensemble d’ellipses représentant une même classe, plutôt qu’une seule.

Deuxièmement, nous avons tracé la translation ainsi que la translation inverse dans la projection 2D. Dans certains cas, tels que dans la figure 3a, la translation peut générer un chiffre cohérent, dont le décodage puis le rencodage permet d’obtenir un vecteur latent assez similaire. Ainsi, la translation inverse se déroule comme prévu. Dans d’autres cas tels que dans la figure 3b,

nous voyons en revanche que le décodage et le rencodage est problématique puisque le vecteur latent obtenu n'est plus le même. Alors, nous transformons ce chiffre vers une mauvaise autre classe, en un mauvais autre chiffre.

Dernièrement, bien que la translation dans la figure 3a soit correcte, elle ne garantit pas que le vecteur latent obtenu dans l'espace à 128 dimensions soit cohérent (voir figure 2a), car la projection abstrait un grand nombre de détails du fait qu'elle n'est pas bijective.




FIGURE 3 – Projection UMAP de la méthode de translation

3 Travail à effectuer

- Continuer la recherche d'une méthode de chiffrement par clé indépendante des classes source et destination ;
- Continuer l'analyse des traces ainsi que l'implémentation d'une méthode de défense contre la reconnaissance de la classe source ;
- Explorer les méthodes d'empoisonnement (voir [2] et [1]) afin de tromper le classifieur dans la détection de la classe source ;
- Éventuellement, étudier des méthodes permettant de séparer le style et la classe en des vecteurs latents continus, à l'inverse de discrets tels que dans un CVAE.

4 Activités

Réunions :

- Présentations dans le cadre du PEPR Cybersécurité - Lundi 24/03/25
 - «Présentation du PEPR Cybersécurité et des activités de recherche de l'équipe ICAR dans le cadre du projet COMPROMIS » par William Puech - LIRMM, Montpellier
 - «Présentation des activités de recherche du laboratoire GREYC dans le cadre du projet COMPROMIS » par Christophe Rosemberger - GREYC, Caen
 - «Détection des deepfakes : méthodes de l'état de l'art appliquées à un cas pratique » par Vincent Itier - CRISAL, Lille
 - «Explicabilité des systèmes biométriques » par Augustin Diers - GREYC, Caen

- «*Manipulation des représentations latentes pour l'édition des visages* » par Lilian Bour
- GREYC, Caen
- «*Obscuration réversible d'images pour l'anonymisation de visages* » par Norman Hutte
- LIRMM, Montpellier
- «*Obscuration de chiffres dans des images par translation de vecteurs latents* » par moi
- LIRMM, Montpellier
- Réunion et discussion autour de la recherche dans le cadre du PEPR Cybersécurité : sécurité multimédia, imagerie faciale, biométrie, ... - Mardi 25/03/25

Références

- [1] Ian J. Goodfellow, Jonathon Shlens, and Christian Szegedy. Explaining and harnessing adversarial examples, 2015.
- [2] Pol Labarbarie. *Transferable adversarial patches : a potential threat for real-world computer vision algorithms*. PhD thesis, Milad Informatique université Paris-Saclay, 2024.