

Compte-rendu hebdomadaire

Compte-rendu 11

Valentin Noyé

1 avril 2025 - 4 avril 2025

GitHub : <https://github.com/owilo/Stage>

1 Problématique

Pour déterminer la nature des traces, nous pouvons explorer en détail la distribution des vecteurs, en émettant l'hypothèse qu'elle suit une loi normale multidimensionnelle. Sous cette hypothèse, le problème des traces précédemment observé lors de la translation et de défense contre la reconnaissance de la classe source lors de l'obscurisation se réduit à une question statistique, où la transformation d'une instance d'une classe à une autre devient un problème de transformation de la distribution source vers la distribution cible, et où la covariance entre les dimensions latentes est une mesure supplémentaire qui rentre en jeu.

2 Travail réalisé

2.1 Début de rédaction d'un article

Cette semaine, en plus de la recherche, j'ai commencé la rédaction de l'article expliquant la méthode d'obscurisation par translation ainsi que quelques résultats quantitatifs obtenus.

2.2 Étude et transformation de la distribution normale multidimensionnelle d'un vecteur latent

2.2.1 Analyse de la distribution des caractéristiques latentes

Nous savons que les caractéristiques latentes de notre vecteur sont entrelacées, donc dépendantes. Si nous pouvons prouver expérimentalement que ces caractéristiques suivent une loi normale, alors notre vecteur latent suit une loi normale multidimensionnelle. Ainsi, nous pourrions utiliser une méthode de transformation de cette distribution vers une autre, sans avoir à recourir à des méthodes complexes de transformation basées sur un transport optimal.

On introduit le score KS, défini par la métrique $D_n = \max_n |F_n(x) - \Phi(x)|$, où $F_n(x)$ est la fonction de répartition empirique basée sur n échantillons, et $\Phi(x)$ celle de la loi normale dont les paramètres μ et σ sont estimés à partir de la distribution observée. L'échantillon est représenté de trois manières : par classe, par dimension, et par classe pour une dimension donnée. On utilise D_n pour calculer la valeur p , en fixant un seuil $\alpha = 0,05$. Ainsi, une valeur $p > \alpha$ indique que la différence entre les deux distributions est trop faible pour conclure qu'elles sont statistiquement différentes.

La figure 1 montre, pour chaque dimension, des scores KS relativement faibles ainsi que des valeurs de $p > \alpha$ dans certains cas, ce qui nous permet de conclure que la plupart des distributions observées diffèrent peu d'une distribution normale. Cette hypothèse est renforcée par les graphes

adjacents : pour chaque classe, et sur l'ensemble du dataset, nous obtenons $p_\mu > \alpha$ et des scores KS $D_n < 3 \cdot 10^{-2}$.




FIGURE 1 – Scores KS et valeurs p

Nous nous intéressons à présent aux dimensions latentes z_0, z_{42}, z_{58} où z_{42} et z_{58} correspondent respectivement aux dimensions ayant les meilleures et les pires certitudes que leurs distributions suivent une loi normale. Nous constatons dans la figure 2 que pour ces dimensions latentes, nous sommes en mesure, qualitativement et quantitativement, de considérer ces distributions comme semblables à des distributions normales. On estime qu'il est toujours possible d'augmenter le facteur β de notre β -VAE afin d'enforcer cette contrainte sur la distribution des dimensions latentes.




FIGURE 2 – Distribution de quelques dimensions latentes par classe

Par ailleurs, cela nous permet de déduire que la classification peut être effectuée directement sur un vecteur latent, en utilisant les distributions spécifiques à chaque classe pour identifier la classe la plus pertinente.

2.2.2 Transformation d'un chiffre

Pour effectuer notre transformation d'une distribution normale multidimensionnelle vers une autre, nous calculons la moyenne μ_i et la matrice de covariance Σ_i à partir des échantillons de chaque classe du dataset d'entraînement. On applique ensuite une transformation de blanchiment (whitening) qui consiste à transformer les données de la classe source afin qu'elles aient une matrice de covariance égale à l'identité, ce qui revient mathématiquement à centrer les données. Nous réajustons ensuite les échantillons de la classe source vers la classe cible en appliquant la matrice de covariance Σ_j et la moyenne μ_j de la classe cible.

Nous comparons dans la figure 3 les résultats de translation inverse obtenus à partir d’une translation simple effectuée depuis la classe des 2 vers les autres classes. Nous observons alors un plus grand nombre de bons résultats qu’auparavant, bien que certains chiffres demeurent difficilement interprétables. Ce phénomène pourrait s’expliquer par le fait que certaines classes partagent des dimensions entrelacées, ce qui complique la projection de la distribution source vers la distribution cible.




FIGURE 3 – Tables de transformation à partir de la classe source 2

Les résultats des différentes classifications sont présentés dans le tableau 1. Ils nous permettent de comparer l’efficacité de notre nouvelle méthode aux approches précédentes, en ce qui concerne la suppression des traces au cours de la transformation. On observe des performances très satisfaisantes, avec une classification proche du hasard — ce qui est précisément l’effet recherché dans un cadre de défense contre la reconnaissance de la classe d’origine. On peut supposer que les 4,63% supplémentaires proviennent de l’entrelacement mentionné précédemment, ainsi que de certaines déviations de notre distribution par rapport à la distribution normale, ce qui pourrait être corrigé en ajustant le facteur β du β -VAE.

Classification	Translation β -VAE	+ normalisation	+ covariance	CVAE
Transformation	86,77%	89,13%	94,61%	99,18%
Trans. inverse	96,41%	96,15%	95,16%	99,73%
Délect. de la trans.	99,84%	99,79%	—	—
Reco. classe source	71,75%	67,79%	14,63%	21,63%

TABLE 1 – Comparaison de la précision de nos différentes méthodes

Ces classifications peuvent être consultées plus en détail dans la figure 4.




FIGURE 4 – Diverses classifications obtenues à partir de la nouvelle méthode

3 Travail à effectuer

- Continuer la rédaction de l'article ;
- Continuer la recherche d'une méthode de chiffrement par clé indépendante des classes source et destination ;
- Explorer les méthodes d'empoisonnement (voir [2] et [1]) afin de tromper le classifieur dans la détection de la classe source ;

- Éventuellement, étudier des méthodes permettant de séparer le style et la classe en des vecteurs latents continus, à l'inverse de discrets tels que dans un CVAE.

4 Activités

Réunions :

- GDR IASIS - «*Détection de contenus générés*» - Paris - Vendredi 04/04/25
 - «*From detection to characterization : what can we tell about an image modification ?* » par Ewa Kijak - IRISA, Rennes
 - «*Latent representation manipulation for face editing* » par Lilian Bour - GREYC, Caen
 - «*MOSAIC : Machine-generated text detection in an unsupervised setting* » par Matthieu Dubois - ISIR, Paris
 - «*Curriculum Learning for Fake Speech detection (CLeFS)* » par Aghilas Sini - LIUM, Le Mans

Références

- [1] Ian J. Goodfellow, Jonathon Shlens, and Christian Szegedy. Explaining and harnessing adversarial examples, 2015.
- [2] Pol Labarbarie. *Transferable adversarial patches : a potential threat for real-world computer vision algorithms*. PhD thesis, Milad Informatique université Paris-Saclay, 2024.