

Compte-rendu hebdomadaire

Compte-rendu 12

Valentin Noyé

7 avril 2025 - 11 avril 2025

GitHub : <https://github.com/owilo/Stage>

1 Problématique

En plus de la rédaction de l'article, la compréhension de la structure de l'espace latent ouvre la voie à de nouvelles expériences détaillées dans ce compte-rendu.

2 Travail réalisé

2.1 Poursuite de la rédaction de l'article

La méthode a été expliquée plus en détail dans l'ébauche de l'article, complétée par des algorithmes et figures.

2.2 Analyse de la covariance des dimensions

Pour confirmer la corrélation entre plusieurs dimensions, la figure 1 met en valeur pour deux classes ainsi que pour tout le dataset, la covariance entre chacune des composantes sous forme matricielle. Il est clair qu'elle est alors à prendre en compte car nous n'obtenons pas une matrice diagonale où seulement la variance contrôlerait les écarts dans ces distributions.




FIGURE 1 – Analyse de la covariance de différents groupes de données dans l'espace latent

2.3 Classification statistique

Car chaque classe suit une loi normal multidimensionnelle, nous pouvons tirer parti de ces distributions pour construire un classifieur quadratique, dont le fonctionnement est basé sur l'analyse discriminante quadratique (QDA). La figure 2 montre la différence entre une classification par l'emploi d'un classifieur CNN face à une classification QDA sur des vecteurs latents

d'images de test MNIST encodées par notre auto-encodeur. Ces tests font voir que la précision de cette classification est relativement élevée (96,72%) mais ne dépasse pas celle de la classification par réseau de neurones (98,98% après réentraînement).




FIGURE 2 – Comparaison de méthodes de classification

2.4 Échantillonnage par classe

À présent, nous tirons des échantillons aléatoires dans la distribution de nos 10 classes MNIST. La figure 3 nous permet de constater que l'échantillonnage prenant en compte la covariance (figure de droite) admet une plus grande gamme de chiffres stylisés, tandis que l'échantillonnage normal sous l'hypothèse d'indépendance des dimensions semble générer des images très proches du prototype des classes.




FIGURE 3 – Échantillonnage aléatoire de chiffres dans chacune des classes

3 Travail à effectuer

- Continuer la rédaction de l'article ;
- Continuer la recherche d'une méthode de chiffrement par clé indépendante des classes source et destination ;
- Explorer les méthodes d'empoisonnement (voir [2] et [1]) afin de tromper le classifieur dans la détection de la classe source ;
- Éventuellement, étudier des méthodes permettant de séparer le style et la classe en des vecteurs latents continus, à l'inverse de discrets tels que dans un CVAE.

4 Activités

Réunions :

- Réunion de suivi - Jeudi 10/04/25

Références

- [1] Ian J. Goodfellow, Jonathon Shlens, and Christian Szegedy. Explaining and harnessing adversarial examples, 2015.
- [2] Pol Labarbarie. *Transferable adversarial patches : a potential threat for real-world computer vision algorithms*. PhD thesis, Milad Informatique université Paris-Saclay, 2024.