

Compte-rendu hebdomadaire

Compte-rendu 13

Valentin Noyé

14 avril 2025 - 18 avril 2025

GitHub : <https://github.com/owilo/Stage>

1 Problématique

Afin de limiter la capacité d'un classifieur à reconnaître la classe source lors de l'obscurité, il est pertinent d'intégrer un facteur de perturbation qui n'altère que faiblement l'apparence visuelle des images tout en compliquant quantitativement leur reconnaissance par d'éventuels attaquants; cette méthode est ensuite décrite en détail dans notre article.

2 Travail réalisé

2.1 Poursuite de la rédaction de l'article

Cette semaine a été principalement dédiée à la rédaction de l'article, dont la méthode est désormais en grande partie finalisée. En plus de cela, certains résultats ont été renseignés bien que nous avons toujours la possibilité d'en rajouter et de les améliorer.

2.2 Implémentation de la méthode d'obscurité

La méthode d'obscurité a été mise en place telle qu'expliquée dans la section III (Méthode) de l'article. La figure 1 montre les résultats de cette méthode pour différentes clés K . La perturbation α ne change que très légèrement les images traduites sans introduire pour autant beaucoup de distorsion.




FIGURE 1 – Obscuration par translation. Par ligne : Source, Translaté, Translaté $+\alpha$, Inverse

L'opération a été menée de la même façon en appliquant un léger bruit gaussien sur la matrice de covariance lors de notre transformation multidimensionnelle. La figure 2 montre des résultats similaires à la précédente méthode tout en améliorant faiblement la qualité de reconstruction des images.




FIGURE 2 – Obscuration par transformation multidimensionnelle. Par ligne : Source, Translaté, Translaté $+\alpha$, Inverse

Nous procédons désormais à l'évaluation de nos différentes classifications sur les transformations intégrant une perturbation, comme indiqué dans le tableau 1. On souligne que les classifieurs ainsi que les détecteurs de traces ont été entraînés en tenant compte de cette perturbation α . En revanche, nous ne montrons pas dans ce tableau les précisions lors de la détection de la translation car celle-ci nécessite un futur réentraînement.

Les résultats présentés dans ce tableau révèlent que, quelle que soit la méthode de transformation appliquée à un chiffre, on observe une dégradation notable de la qualité d'obscurité, accompagnée d'une légère diminution de la capacité de désobscurité.

Notons toutefois qu’avec notre méthode de translation, la précision de reconnaissance de la classe source a été divisée par deux, ce qui justifie l’introduction de la perturbation α . En ce qui concerne la transformation multidimensionnelle, la performance en reconnaissance de la classe source se rapproche fortement de celle d’une classification aléatoire.

Classification	Translation	+ α	Transformation	+ α
Transformation	86,77%	81,41%	94,61%	92,94%
Trans. inverse	93,41%	93,13%	95,16%	94,50%
Reco. classe source	71,75%	32,70%	14,63%	12,17%

TABLE 1 – Comparaison de la précision des méthodes avec et sans perturbation α

Pour une analyse plus détaillée de ces résultats, les matrices de confusion associées à ces résultats peuvent être consultées dans la figure 3 suite à l’introduction de la perturbation α .




FIGURE 3 – Comparaison des classifications obtenues à partir des deux variantes de la méthode d’obscurité : (1) Translation, (2) : Transformation multidimensionnelle

3 Travail à effectuer

- Continuer la rédaction de l’article ;
- Continuer la recherche d’une méthode de chiffrement par clé indépendante des classes source et destination ;
- Explorer les méthodes d’empoisonnement (voir [2] et [1]) afin de tromper le classifieur dans la détection de la classe source ;
- Éventuellement, étudier des méthodes permettant de séparer le style et la classe en des vecteurs latents continus, à l’inverse de discrets tels que dans un CVAE.

4 Activités

Aucune activité

Références

- [1] Ian J. Goodfellow, Jonathon Shlens, and Christian Szegedy. Explaining and harnessing adversarial examples, 2015.
- [2] Pol Labarbarie. *Transferable adversarial patches : a potential threat for real-world computer vision algorithms*. PhD thesis, Milad Informatique université Paris-Saclay, 2024.