

Compte-rendu hebdomadaire

Compte-rendu 14

Valentin Noyé

22 avril 2025 - 25 avril 2025

GitHub : <https://github.com/owilo/Stage>

1 Problématique

Cette semaine, l'ensemble des résultats obtenus ont été générés et analysés pour être intégralement incorporés dans la rédaction de l'article.

2 Travail réalisé

2.1 Poursuite de la rédaction de l'article

Tandis que la partie sur la méthode est complétée, plusieurs résultats ont été générés afin qu'ils intègrent proprement la section qui leur est dédiée dans l'article. La majorité des résultats générés cette semaine sont ainsi présentés dans l'ébauche de cette partie de l'article.

2.2 Nouvelle méthode d'entraînement du détecteur de trace

Auparavant, les résultats de notre classification de présence ou d'absence de traces étaient fortement biaisés en raison d'un déséquilibre dans notre jeu de données. Pour remédier à ce problème, nous avons restructuré notre dataset en deux parties égales : une première moitié contenant toutes les images originales, et une seconde regroupant toutes les images obscurcies. Cette répartition équitable garantit désormais que chaque paire (source, destination) contient un nombre comparable d'éléments, tant pour l'entraînement que pour les tests de validation.

Notre évaluation de la performance du classifieur montre qu'indépendamment de la méthode employée (transformation rigide ou multidimensionnelle) et de la présence d'une perturbation α , nous parvenons à détecter l'obscurcissement avec un taux de succès supérieur à 99,50% (voir figure 1). Il est à supposer que le classifieur est capable d'interpréter l'écart de qualité des images originales face aux images générées par notre auto-encodeur.




FIGURE 1 – Matrices de confusion de la détection de l'obscurcissement

3 Travail à effectuer

- Continuer la rédaction de l'article ;
- Continuer la recherche d'une méthode de chiffrement par clé non-supervisée ;
- Explorer les méthodes d'empoisonnement (voir [2] et [1]) afin de tromper le classifieur dans la détection de la classe source ;
- Éventuellement, étudier des méthodes permettant de séparer le style et la classe en des vecteurs latents continus, à l'inverse de discrets tels que dans un CVAE.

4 Activités

Formations :

- Formation NEO - Jeudi 24/04/25 et Vendredi 25/04/25

Références

- [1] Ian J. Goodfellow, Jonathon Shlens, and Christian Szegedy. Explaining and harnessing adversarial examples, 2015.
- [2] Pol Labarbarie. *Transferable adversarial patches : a potential threat for real-world computer vision algorithms*. PhD thesis, Milad Informatique université Paris-Saclay, 2024.