

Compte-rendu hebdomadaire

Compte-rendu 15

Valentin Noyé

28 avril 2025 - 2 mai 2025

GitHub : <https://github.com/owilo/Stage>

1 Problématique

Dans le cadre d'un modèle supervisé où l'on introduit une perte de classification sur le vecteur latent de classe $\mathbf{z}_c$, la dissociation effective des informations de style et de classe dans l'espace latent reste délicate. Il s'agit de définir un cadre méthodologique capable d'exercer une pression spécifique sur le vecteur de style $\mathbf{z}_s$ pour qu'il encode véritablement les attributs stylistiques, tout en maintenant la précision de classification via $\mathbf{z}_c$. Ce compte-rendu présente notamment les différentes stratégies de perte et de priorisation explorées et destinées à garantir une séparation nette entre style et classe dans l'espace latent.

2 Travail réalisé

2.1 Poursuite de la rédaction de l'article

Les résultats ont été développés dans l'ébauche de l'article, avec plusieurs exemples variés, essentiellement centrés sur l'obscurisation et la reconstruction. Dans cette section, il reste à finaliser la comparaison de nos méthodes avec celles de l'état de l'art.

2.2 Améliorations du CVAE

Le CVAE précédemment implémenté nécessitait la connaissance des labels lors de l'inférence. Suite à une modification de ce dernier, l'encodeur classe également l'image en entrée pour prédire un label qui serait utilisé soit pour effectuer l'obscurisation, soit pour le passer au décodeur afin de reconstruire l'image. Le décodeur, quant à lui, prend toujours les vrais labels en entrée lors de l'entraînement pour s'assurer que la reconstruction reste correcte.

Il est aussi possible d'ajuster légèrement le vecteur latent de classe du CVAE, ce qui permet d'introduire des variations dans la reconstruction des chiffres des différentes classes, au détriment de la qualité de reconstruction.

2.3 Pistes de recherche pour la séparation du style et de la classe

Plusieurs autres méthodes ont été explorées afin de séparer le vecteur latent de style $\mathbf{z}_s$ et de classe $\mathbf{z}_c$, à savoir qu'une telle méthode n'est possible que sous supervision par introduction de labels lors de l'entraînement [6], alors nous introduisons une perte de classification sur $\mathbf{z}_c$. Ainsi, en ce qui concerne $\mathbf{z}_s$, ces approches-ci ont été considérées :

- Pénalité de classification sur $\mathbf{z}_s$ par l'utilisation d'une couche d'inversion de gradient [3] ;
- Pénalité de corrélation par covariance croisée entre $\mathbf{z}_s$ et $\mathbf{z}_c$;

- Pénalité de corrélation totale entre z_s et z_c [1] ;
- Perte de reconstruction sur un échange de style sur une paire d'images.

Ces tests ne se sont pas montrés concluants. L'information est majoritairement concentrée dans z_c puisque aucune pression n'est posée sur z_s en ce qui concerne l'encodage de l'information relative au style. En effet, le modèle apprend à satisfaire les conditions qui sont posées sur ce vecteur ; et dans chacun de ces cas, minimiser la perte sur celui-ci revient à affaiblir ou nullifier l'importance de l'information qu'il contient. Ce scénario est alors typique d'un effondrement du postérieur [8]. En revanche, d'autres approches peuvent toujours être considérées :

- Implémenter un autoencodeur variationnel avec une fonction de perte telle InfoVAE [9] ;
- Maximiser l'information mutuelle $I(z_s; x)$ afin de donner une plus forte importance au vecteur latent de style [7] ;
- Employer un prior sous forme de mélange de gaussiennes plutôt qu'un simple prior gaussien [2].

3 Travail à effectuer

- Continuer la rédaction de l'article ;
- Continuer la recherche d'une méthode de chiffrement par clé non-supervisée ;
- Explorer les méthodes d'empoisonnement (voir [5] et [4]) afin de tromper le classifieur dans la détection de la classe source ;
- Éventuellement, étudier des méthodes permettant de séparer le style et la classe en des vecteurs latents continus, à l'inverse de discrets tels que dans un CVAE.

4 Activités

Aucune activité

Références

- [1] Ricky T. Q. Chen, Xuechen Li, Roger Grosse, and David Duvenaud. Isolating sources of disentanglement in variational autoencoders, 2019.
- [2] Nat Dilokthanakul, Pedro A. M. Mediano, Marta Garnelo, Matthew C. H. Lee, Hugh Salimbeni, Kai Arulkumaran, and Murray Shanahan. Deep unsupervised clustering with gaussian mixture variational autoencoders, 2017.
- [3] Yaroslav Ganin and Victor Lempitsky. Unsupervised domain adaptation by backpropagation, 2015.
- [4] Ian J. Goodfellow, Jonathon Shlens, and Christian Szegedy. Explaining and harnessing adversarial examples, 2015.
- [5] Pol Labarbarie. *Transferable adversarial patches : a potential threat for real-world computer vision algorithms*. PhD thesis, Milad Informatique université Paris-Saclay, 2024.
- [6] Francesco Locatello, Stefan Bauer, Mario Lucic, Gunnar Rätsch, Sylvain Gelly, Bernhard Schölkopf, and Olivier Bachem. Challenging common assumptions in the unsupervised learning of disentangled representations, 2019.
- [7] Andriy Serdega and Dae-Shik Kim. Vmi-vae : Variational mutual information maximization framework for vae with discrete and continuous priors. 2019.
- [8] Yixin Wang, David M. Blei, and John P. Cunningham. Posterior collapse and latent variable non-identifiability, 2023.
- [9] Shengjia Zhao, Jiaming Song, and Stefano Ermon. Infovae : Information maximizing variational autoencoders, 2018.