

Compte-rendu hebdomadaire

Compte-rendu 16

Valentin Noyé

5 mai 2025 - 9 mai 2025

GitHub : <https://github.com/owilo/Stage>

1 Problématique

Pour renforcer la structuration de l'espace latent en groupes distincts et nettement séparés, ce qui reste un enjeu majeur, il est pertinent d'employer, en guise de distribution a priori dans un VAE, un mélange de lois gaussiennes multivariées (GMM).

2 Travail réalisé

2.1 Rédaction des articles

Une comparaison entre les différentes méthodes et la nôtre a été ajoutée. Parmi ces méthodes, on inclut la méthode d'empoisonnement PGD [2] basée sur un fonctionnement itératif de la méthode FGSM [1] précédemment exploré. Par ailleurs, la rédaction d'un nouvel article pour ICIP 2025 est en cours et fait l'objet d'une priorité par rapport à l'article principal.

2.2 Modification du prior du VAE

Le prior du VAE a été remplacé par un mélange gaussien (GMM) à 10 composantes, en lieu et place du prior gaussien multidimensionnel initial. Cette modification permet d'entraîner le modèle à former naturellement des clusters en paramétrant directement μ_i et Σ_i , la moyenne et la covariance de chaque composante, ce qui élimine la nécessité de calculer ces paramètres lors de la phase de prétraitement. Une perte de classification a été ajoutée afin de mieux contraindre l'espace latent à structurer ces clusters en les séparant davantage. Bien que des résultats préliminaires aient été obtenus, des résultats plus formels restent à générer.

3 Travail à effectuer

- Continuer la rédaction de l'article ICIP 2025 ;
- Continuer la rédaction de l'article IEEE ;
- Continuer la recherche d'une méthode de chiffrement par clé sans se baser sur les classes source et cible ;
- Éventuellement, étudier des méthodes permettant de séparer le style et la classe en des vecteurs latents continus, à l'inverse de discrets tels que dans un CVAE.

4 Activités

Réunions :

— Réunion de suivi - Mercredi 07/05/25

Références

- [1] Ian J. Goodfellow, Jonathon Shlens, and Christian Szegedy. Explaining and harnessing adversarial examples, 2015.
- [2] Aleksander Madry, Aleksandar Makelov, Ludwig Schmidt, Dimitris Tsipras, and Adrian Vladu. Towards deep learning models resistant to adversarial attacks, 2019.