

Compte-rendu hebdomadaire

Compte-rendu 18

Valentin Noyé

19 mai 2025 - 23 mai 2025

GitHub : <https://github.com/owilo/Stage>

1 Problématique

Un axe central de ce travail mené sur plusieurs mois réside dans la capacité à dissocier le style visuel de la classe sémantique des images. Cette avancée permet d'envisager des méthodes d'obscurisation qui préservent le style tout en masquant le contenu de l'image. Parmi ces approches, une méthode d'obscurisation indépendante de la classe de l'image en entrée est proposée, reposant sur l'architecture d'autoencodeurs précédemment étudiée et leurs spécificités.

2 Travail réalisé

2.1 Rédaction des articles

La rédaction de l'article destiné à IEEE peut désormais reprendre, la soumission pour ICIP 2025 ayant été finalisée. Par ailleurs, la rédaction du mémoire de stage peut également débuter.

2.2 Séparation de la classe et du style

Afin d'appliquer une obscurisation complète du contenu d'une image en un autre, la séparation de la classe et du style en deux vecteurs latents $\mathbf{z}_c$ et $\mathbf{z}_s$ peut être considérée. En particulier, nous avons constaté précédemment que le GMVAE pouvait être utilisé pour sa qualité à structurer l'espace latent en clusters organisés. L'implémentation décrite par Dilokthanakul *et al.* [1] emploie notamment une approche non-supervisée dans la formation des clusters, ce qui ne contraint pas les classes dans des clusters différents, mais les encourage plutôt à se répartir dans plusieurs clusters ; nous utilisons alors ce principe afin de construire $\mathbf{z}_c$. Quant à l'entraînement de ce modèle, nous utilisons une fonction de perte construire selon différentes observations et hypothèses émises au cours du développement d'un tel modèle,

$$\begin{aligned} L_{\text{total}} = & \alpha_{\text{bce}} L_{\text{bce}} + \alpha_{\text{ssim}} L_{\text{ssim}} \\ & + \beta_{\text{KL}}^c L_{\text{KL}}^c + \beta_{\text{KL}}^s L_{\text{KL}}^s \\ & + \lambda_{\text{class}} L_{\text{cls}} + \lambda_{\text{style}} L_{\text{adv}} + L_{\text{info}} + L_{\text{decor}}. \end{aligned}$$

$L_{\text{bce}}(x, x')$ et $L_{\text{ssim}}(x, x')$: Pertes de reconstruction utilisées, l'une basée sur la divergence binaire croisée et l'autre sur la similarité structurelle destinée à préserver la qualité perceptuelle,

$$\begin{aligned} L_{\text{bce}}(x, x') &= \mathbb{E}[\text{BCE}(x, x')], \\ L_{\text{ssim}}(x, x') &= \mathbb{E}[1 - \text{SSIM}(x, x')]. \end{aligned}$$

L_{KL}^c : Terme de divergence de Kullback–Leibler entre la distribution approximative de la variable de classe z_c et un prior GMM, favorisant la formation de clusters plus naturels qu’avec un prior gaussien,

$$L_{\text{KL}}^c = \text{KL}[q(z_c | x) \| p_{\text{GMM}}(z_c)].$$

L_{KL}^s : Terme de régularisation de la variable de style z_s , encourageant sa distribution à se rapprocher d’une loi normale standard,

$$L_{\text{KL}}^s = \text{KL}[q(z_s | x) \| \mathcal{N}(I, 0)].$$

L_{cls} : Perte de classification supervisée appliquée au vecteur z_c , utilisée pour guider l’encodage vers une représentation discriminative des classes,

$$L_{\text{cls}} = \mathbb{E}[\text{C}(y, f_c(z_c))].$$

L_{adv} : Perte adversariale sur la branche de style z_s , qui, à l’aide une inversion de gradient (GRL pour "Gradient Reversal Layer") [2], cherche à rendre l’information de classe non détectable dans l’espace style en pénalisant la capacité de z_s à émettre de l’information relative à la classe,

$$L_{\text{adv}} = \mathbb{E}[\text{C}(y, f_s(\text{GRL}(z_s))].$$

L_{info} : Perte InfoNCE [4] visant à maximiser la corrélation mutuelle entre représentations style et contenu, pour renforcer la dépendance utile en pénalisant le vecteur latent en matière de génération de bruit,

$$L_{\text{info}} = \text{InfoNCE}(x, z_s).$$

Ce terme est tout particulièrement nécessaire, car les différentes approches précédemment explorées ne l’employaient pas. Ainsi, nous tombions dans un cas classique d’effondrement du postérieur, où la branche de style z_s n’encodait aucune information.

L_{decor} : Terme de dé-corrélation pénalisant la covariance croisée entre z_c et z_s , afin de garantir que les informations de classe et de style restent indépendantes,

$$L_{\text{decor}} = \sum_{i,j} [\text{Cov}(z_c, z_s)]_{i,j}^2.$$

Le modèle s’articule autour de trois niveaux empilés de blocs résiduels : dans l’encodeur, à chaque palier la taille des blocs résiduels et le nombre de convolutions sont doublés, tandis que dans le décodeur ils sont divisés par deux. Le vecteur latent de chaque branche (z_c et z_s) est dimensionné à 32, ce qui permet une reconstruction satisfaisante des images MNIST.

L’entraînement s’est déroulé sur 50 époques, avec un recuit linéaire du coefficient β pendant les 30 premières époques, et un scheduler qui divise par deux le taux d’apprentissage (initialement fixé à 0,002) toutes les 8 époques sans amélioration du gradient, en utilisant l’optimiseur Adam. Un batch size de 32 a été retenu. Le modèle apprend simultanément à structurer l’espace latent des deux branches et, plus spécifiquement dans la branche z_c , à ajuster un mélange de 20 gaussiennes pour modéliser la distribution de ses représentations.

Le choix des hyperparamètres est critique pour éviter l’explosion du gradient tout en conservant une bonne qualité de reconstruction et de génération, car celui est fragile. Les valeurs retenues sont renseignées dans le tableau 1, mais à ce jour, de meilleurs hyperparamètres peuvent encore être trouvés afin d’améliorer l’efficacité du modèle.

α_{bce}	α_{ssim}	β_{KL}^c	β_{KL}^s	λ_{cls}	λ_{adv}
1	2	1	1	2	10,5

TABLE 1 – Hyperparamètres du GMVAE

Tout d’abord, nous constatons les capacités de reconstruction de notre modèle dans la figure 1, où ces dernières sont relativement correctes. La première ligne représente les images originales, la seconde les images reconstruites.



FIGURE 1 – Reconstruction de différents chiffres de MNIST

Pour démontrer les capacités de démêlage du style et de la classe, nous montrons dans la figure 2 différents résultats générés par notre expérience de "style-swapping" : sur chaque ligne, on représente à gauche la paire d’images originales, et à droite, la même paire dont le style a été échangé.




FIGURE 2 – Différents tests de "style-swapping"

Nous obtenons globalement de bons résultats, mais la qualité se dégrade lors du décodage. Pour y remédier, plusieurs pistes s’offrent à nous : d’une part, accroître significativement le nombre d’époques, car certains paramètres n’avaient pas encore pleinement convergé ; d’autre part, le style des chiffres pourrait manquer d’expressivité pour couvrir toute la diversité des images générés. On pourrait alors, par exemple, appliquer un mélange de gaussiennes en tant que prior sur z_s , comme nous le faisons déjà pour z_c , ou encore enrichir le jeu de données afin de propager les variations stylistiques sur une surface d’image plus étendue.

2.3 Méthode d’obscurisation sans classification

Auparavant, l’obscurisation reposait sur la connaissance des classes sources : la clé permettait avant tout d’identifier la classe à masquer. Dans la nouvelle approche, nous nous appuyons sur un GMVAE et plus spécifiquement celui de la section 2.2, dont l’espace latent n’est pas structuré par supervision : plusieurs clusters peuvent contenir des images de différentes classes. Nous n’estimons donc plus explicitement la distribution de chaque classe (moyenne et covariance) comme précédemment.

À la place, nous supposons que le mélange gaussien dans l’espace latent peut être remanié pour obéir à une loi uniforme sur l’hypercube $[0, 1]^d$ avec d la dimension de l’espace latent. Concrètement, les régions à forte densité (correspondant à des représentations cohérentes) sont étirées, tandis que les zones clairsemées sont comprimées. Cette opération s’effectue au moyen de la transformation de Rosenblatt [3], réversible par définition.

Le protocole est alors le suivant :

- On détermine pour un vecteur latent z_c , sa position transformée w_c dans l'hypercube $[0, 1]^d$.
- On applique à w_c un vecteur de translation pseudo-aléatoirement généré à partir d'une clé secrète K .
- On inverse la transformation de Rosenblatt pour revenir dans l'espace latent et obtenir z_c^* , le vecteur de l'image obscurcie.

En théorie, de légères modifications de l'image d'origine entraînent de faibles changements dans l'image obscurcie. Seules des discontinuités mineures peuvent apparaître lorsqu'on traverse la frontière de deux clusters ou celle de l'hypercube ; dans ce dernier cas, on ajuste simplement le déplacement pour qu'il "rebondisse" à l'intérieur de l'hypercube.

Dans la figure 3, nous appliquons l'obscurisation sur le chiffre source (lignes impaires) pour obtenir un nouveau chiffre obscurci (lignes paires) avec un style similaire. Nous observons le même défaut de reconstruction que dans la figure 2, ce qui a été discuté dans la section 2.2.




FIGURE 3 – Obscurisation de différents chiffres de MNIST avec la nouvelle méthode

Par ailleurs, cette méthode d'obscurisation génère des meilleures images sur notre GMVAE à 1 branche, mais les reconstructions sont légèrement plus floues.

3 Travail à effectuer

- Implémenter ou utiliser un OCR afin d'appliquer une méthode d'obscurisation sur une image composée d'images de chiffres MNIST ;
- Continuer la rédaction de l'article IEEE ;
- Commencer la rédaction du mémoire de stage.

4 Activités

Réunions :

- «Introduction à la pédagogie universitaire » par Nicolas Lutz - "Speech Lunch" - Mercredi 21/05/25

Références

- [1] Nat Dilokthanakul, Pedro A. M. Mediano, Marta Garnelo, Matthew C. H. Lee, Hugh Salimbeni, Kai Arulkumaran, and Murray Shanahan. Deep unsupervised clustering with gaussian mixture variational autoencoders, 2017.
- [2] Yaroslav Ganin and Victor Lempitsky. Unsupervised domain adaptation by backpropagation, 2015.
- [3] Murray Rosenblatt. Remarks on a multivariate transformation. *The Annals of Mathematical Statistics*, 23(3) :470–472, September 1952.
- [4] Aaron van den Oord, Yazhe Li, and Oriol Vinyals. Representation learning with contrastive predictive coding, 2019.