

Obscuration de chiffres dans des images par translation de vecteurs latents

Valentin NOYÉ¹, William PUECH¹, Pauline PUTEAUX²

¹**LIRMM**, Univ Montpellier, CNRS

²**CRIStAL**, Univ Lille, CNRS

Contexte

- **Protection des données** et de la vie privée
- Importance de l'information dans les médias visuels
- Obscuration **réversible** à partir d'une clé
- Bonne **fidélité visuelle** et **invisible**



Solution

Obscuration



Désobscuration

Sommaire


- Introduction
- Obscuration de chiffres
 - Méthode
 - Résultats expérimentaux
- Attaque (et défense)
 - Méthode
 - Résultats expérimentaux
- Conclusion et perspectives

Sommaire


- Introduction
- Obscuration de chiffres
 - Méthode
 - Résultats expérimentaux
- Attaque (et défense)
 - Méthode
 - Résultats expérimentaux
- Conclusion et perspectives

Calcul des vecteurs de translation


Calcul du centroïde de la classe c_i



Calcul de la translation de la classe source c_i vers la classe cible c_j



Obscuration




Formule de la translation de la classe i vers la classe j :


$$V_T = V_{I'} + V_{i \rightarrow j}$$

Les classes source et cible sont connues


Étape d'obscuration



Étape de désobscuration



Désobscuration




Formule de la translation inverse
(classe **j** vers la classe **i**) :

$$V_T^{-1} = V_T + V_{j \rightarrow i}$$

Les classes source et cible sont
connues

Évaluation de l'obscuration (classification)




Sommaire

- Introduction
- Obscuration de chiffres
 - Méthode
 - Résultats expérimentaux
- Attaque (et défense)
 - Méthode
 - Résultats expérimentaux
- Conclusion et perspectives


Dataset

- Dataset d'images dessinées **MNIST**
- **60 000** images d'entraînement
- **10 000** images de test



Modèles

Autoencodeur variationnel





- Facteur β de démêlage
- Vecteur latent de taille 128


Classifieur

- 99,29% de précision sur la base de données MNIST
- 99,26% de certitude sur MNIST




Prototypes






Obscuration




Translation de chiffres



Translation de chiffres




Classification de l'obscuration



Précision : 86,77%
Certitude : 94,17%

Distribution de la certitude des prédictions




Désobscuration


Source




(0, 1.000)



(2, 1.000)



Classification de la désobscuration




Précision : 96,41%
Certitude : 97,54%

Sommaire


- Introduction
- Obscuration de chiffres
 - Méthode
 - Résultats expérimentaux
- Attaque (et défense)
 - Méthode
 - Résultats expérimentaux
- Conclusion et perspectives

Détection de l'obscurité

Obscuration




Entraînement du classifieur




Reconnaissance de la classe source (traces)

Obscuration



Entraînement du classifieur




Sommaire


- Introduction
- Obscuration de chiffres
 - Méthode
 - Résultats expérimentaux
- Attaque (et défense)
 - Méthode
 - Résultats expérimentaux
- Conclusion et perspectives

Reconnaissance de la classe source (traces)

Source




Reconnaissance de la classe source dans la translation (traces)



Précision : 99,84%

Certitude : 99,95%

Reconnaissance de la classe source (traces)



Précision : 71,75%
Certitude : 87,24%

Conclusion

→ Efficace :

→ Obscuration

~86% de précision de classification classe cible et ~12% classe non-source

→ Invisible

→ Réversible

~94% de précision de classification

→ Attaquable (analyse des traces) :

→ Forte reconnaissance des traces de la classe source


~72% de précision de classification

→ Détectable

~100% de précision de classification

Perspectives

→ **Méthode de chiffrement** : intégration d'une clé, choix du vecteur de translation, d'un angle et d'un ratio



→ **Défense** : suppression des traces dans la translation

Perspectives

→ **Empoisonnement** : tromper le classifieur



x

“panda”

57.7% confidence

$+ .007 \times$



$\text{sign}(\nabla_x \mathcal{L}_{CE}(F_\theta(x), y_{tgt}))$

“nematode”

8.2% confidence

$=$



$x +$






$\epsilon \text{sign}(\nabla_x \mathcal{L}_{CE}(F_\theta(x), y_{tgt}))$

“gibbon”

99.3 % confidence

Perspectives

→ **CVAE** (VAE conditionnel) : découplage du style (trace?) et de la classe



Références

→ *β -VAE: Learning Basic Visual Concepts with a Constrained Variational Framework*

Irina Higgins, Loic Matthey, Arka Pal, Christopher Burgess, Xavier Glorot, Matthew Botvinick, Shakir Mohamed, Alexander Lerchner

International Conference on Learning Representations (ICLR), 2017

→ *Transferable Adversarial Patches : A Potential Threat for Real-World Computer Vision Algorithms*

Pol Labarbarie

PhD Thesis, Milad Informatique Université Paris-Saclay, 2024

→ *Learning Disentangled Representations With Semi-Supervised Deep Generative Models*

N. Siddharth, Brooks Paige, Jan-Willem van de Meent, Alban Desmaison, Noah D. Goodman, Pushmeet Kohli, Frank Wood, Philip H. S. Torr. L

31st Conference on Neural Information Processing Systems (NIPS), 2017