

Obscuration de chiffres dans des images par translation de vecteurs latents

Valentin NOYÉ, William PUECH, Pauline PUTEAUX, Norman HUTTE

LIRMM, Univ Montpellier, CNRS

Contexte

- Importance de l'information dans les médias visuels
- **Protection des données** et de la vie privée
- Bonne **fidélité visuelle** et **invisible**
- Obscuration **réversible** à partir d'une clé



Solution

Obscuration



Désobscuration

Sommaire


- Introduction
- Obscuration de chiffres
 - Méthode
 - Résultats expérimentaux
- Attaque (et défense)
 - Méthode
 - Résultats expérimentaux
- Conclusion et perspectives

Sommaire


- Introduction
- Obscuration de chiffres
 - Méthode
 - Résultats expérimentaux
- Attaque (et défense)
 - Méthode
 - Résultats expérimentaux
- Conclusion et perspectives

Calcul des vecteurs de translation


Calcul du centroïde de la classe c_i



Calcul de la translation de la classe source c_i vers la classe cible c_j



Obscuration




Formule de la translation de la classe i vers la classe j :


$$V_T = V_{I'} + V_{i \rightarrow j}$$

Les classes source et cible sont connues


Étape d'obscuration



Étape de désobscuration



Désobscuration




Formule de la translation inverse
(classe **j** vers la classe **i**) :

$$V_{\hat{i}} = V_T + V_{j \rightarrow i}$$

Les classes source et cible sont
connues

Évaluation de l'obscurisation (classification)




Sommaire

- Introduction
- Obscuration de chiffres
 - Méthode
 - Résultats expérimentaux
- Attaque (et défense)
 - Méthode
 - Résultats expérimentaux
- Conclusion et perspectives


Dataset

- Dataset d'images dessinées **MNIST**
- **60 000** images d'entraînement
- **10 000** images de test



Modèles

Autoencodeur variationnel



→ Facteur β de démêlage

→ Vecteur latent de taille 128

Classifieur



→ 99,29% de précision et 99,26% de certitude sur la base de données MNIST

Modèle : *Understanding disentangling in β -VAE*


Christopher P. Burgess, Irina Higgins, Arka Pal, Loic Matthey, Nick Watters, Guillaume Desjardins, Alexander Lerchner

31st Conference on Neural Information Processing Systems (NIPS), 2017




Prototypes





Obscuration




Translation de chiffres



Translation de chiffres



Classification de l'obscuration



Précision : 85,79%
Classe source : 1,59%
Autre classe : 12,62%

% obscurci : 98.41%


Certitude : 94,17%

Désobscuration

Source




(0, 1.000) ✓



✓




(2, 1.000) ✓



✓

Classification de la désobscuration




Précision : 96,41%
Certitude : 97,54%

Sommaire


- Introduction
- Obscuration de chiffres
 - Méthode
 - Résultats expérimentaux
- Attaque (et défense)
 - Méthode
 - Résultats expérimentaux
- Conclusion et perspectives

Détection de l'obscurité

Obscuration




Entraînement du classifieur




Reconnaissance de la classe source (traces)

Obscuration




Entraînement du classifieur



Sommaire


- Introduction
- Obscuration de chiffres
 - Méthode
 - Résultats expérimentaux
- Attaque (et défense)
 - Méthode
 - Résultats expérimentaux
- Conclusion et perspectives

Détection de la translation (traces)




Précision : 99,84%
Certitude : 99,95%

Reconnaissance de la classe source



Reconnaissance de la classe source (traces)



Précision : 71,75%
Certitude : 87,24%

Conclusion

→ Efficace :

→ Obscuration

~86% de précision de classification classe cible et ~12% classe non-source (~98% total)

→ Invisible

→ Réversible

~96% de précision de classification

→ Attaquable (analyse des traces) :

→ Détectable


~100% de précision de classification

→ Forte reconnaissance des traces de la classe source

~72% de précision de classification

Perspectives

→ **Méthode d'obscuration avec clé** : intégration d'une clé, choix du vecteur de translation, d'un angle et d'un ratio



→ **Défense** : suppression des traces dans la translation

Perspectives

→ **Empoisonnement¹** : tromper le classifieur




x

“panda”

57.7% confidence

+ .007 ×



$\text{sign}(\nabla_x \mathcal{L}_{CE}(F_\theta(x), y_{tgt}))$

“nematode”

8.2% confidence

=



$x +$

$\epsilon \text{sign}(\nabla_x \mathcal{L}_{CE}(F_\theta(x), y_{tgt}))$

“gibbon”

99.3 % confidence


Image : *Explaining and Harnessing Adversarial Examples*

Ian J. Goodfellow, Jonathon Shlens, Christian Szegedy

3rd International Conference on Learning Representations (ICLR), 2015

Perspectives

→ **CVAE** (VAE conditionnel) : découplage du style (trace?) et de la classe



Modèle : *Learning Disentangled Representations With Semi-Supervised Deep Generative Models*

N. Siddharth, Brooks Paige, Jan-Willem van de Meent, Alban Desmaison, Noah D. Goodman, Pushmeet Kohli, Frank Wood, Philip H. S. Torr. L

31st Conference on Neural Information Processing Systems (NIPS), 2017

Références

→ *β -VAE: Learning Basic Visual Concepts with a Constrained Variational Framework*

Irina Higgins, Loic Matthey, Arka Pal, Christopher Burgess, Xavier Glorot, Matthew Botvinick, Shakir Mohamed, Alexander Lerchner

5th International Conference on Learning Representations (ICLR), 2017

→ *Explaining and Harnessing Adversarial Examples*

Ian J. Goodfellow, Jonathon Shlens, Christian Szegedy

3rd International Conference on Learning Representations (ICLR), 2015

→ *Transferable Adversarial Patches : A Potential Threat for Real-World Computer Vision Algorithms*

Pol Labarbarie

PhD Thesis, Milad Informatique Université Paris-Saclay, 2024

→ *Learning Disentangled Representations With Semi-Supervised Deep Generative Models*

N. Siddharth, Brooks Paige, Jan-Willem van de Meent, Alban Desmaison, Noah D. Goodman, Pushmeet Kohli, Frank Wood, Philip H. S. Torr. L

31st Conference on Neural Information Processing Systems (NIPS), 2017